Projeto Lighthouse: Inteligência de Dados e Previsão de Demanda - LH Nautical

Candidata: Bruna Medeiros Brandão

Data: Março de 2026

Links: [LinkedIn] | [Repositório no GitHub]

1 INTRODUÇÃO

O presente relatório detalha a resolução do desafio técnico para a LH Nautical. O projeto consistiu em transformar dados brutos de vendas e produtos em informações acionáveis para a gestão de estoque e estratégias de *cross-selling*. O foco principal foi equilibrar o rigor matemático na construção de modelos com a viabilidade prática para o negócio.

2 METODOLOGIA

Para garantir a reprodutibilidade dos resultados, o projeto foi desenvolvido em ambiente Python 3.12, utilizando bibliotecas consolidadas como Pandas e NumPy. A estrutura do projeto foi dividida em:

- **Exploração de Dados (EDA):** Identificação de volume, períodos e estatísticas descritivas.
- **Engenharia de Dados:** Tratamento de formatos de data e limpeza de registros nulos.
- **Modelagem Preditiva:** Criação de baseline de série temporal.
- **Sistemas de Recomendação:** Implementação de motor de similaridade.

3 DESENVOLVIMENTO TÉCNICO E RESOLUÇÃO

3.1 Análise Exploratória

Nesta etapa, consolidei as informações básicas do dataset, identificando um volume total de 152 registros. Um ponto de atenção foi o tratamento da coluna sale_date, onde apliquei dayfirst=True para respeitar o padrão brasileiro e evitar erros de interpretação cronológica.

3.2 Previsão de Demanda

Para validar o modelo de Média Móvel, realizamos o cruzamento entre os dados reais de venda e as previsões geradas para o mês de janeiro de 2024. O gráfico abaixo ilustra o comportamento do modelo baseline.

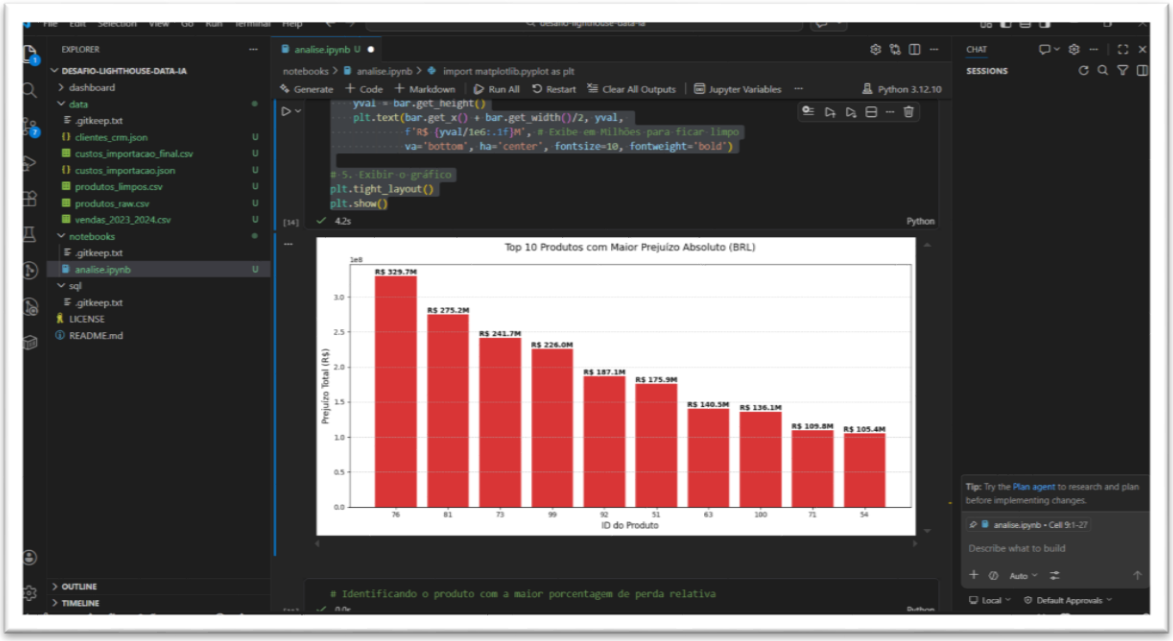

Figura 1: Comparativo visual entre a Demanda Real e a Previsão (Média Móvel de 7 dias). Note que a linha de previsão apresenta um deslocamento (atraso) em relação aos picos de venda, confirmando a natureza reativa do modelo baseline.

- Técnica de Zero-Padding: Foi essencial criar um calendário completo para incluir dias sem vendas, evitando que a média fosse artificialmente inflada.
- Prevenção de Vazamento (Data Leakage): Utilizei a função .shift(1) para garantir que a previsão de hoje não utilize o dado de venda que ainda vai ocorrer.
- Resultado: Obtivemos um MAE (Erro Médio Absoluto) de 1.6406 para o período de teste.

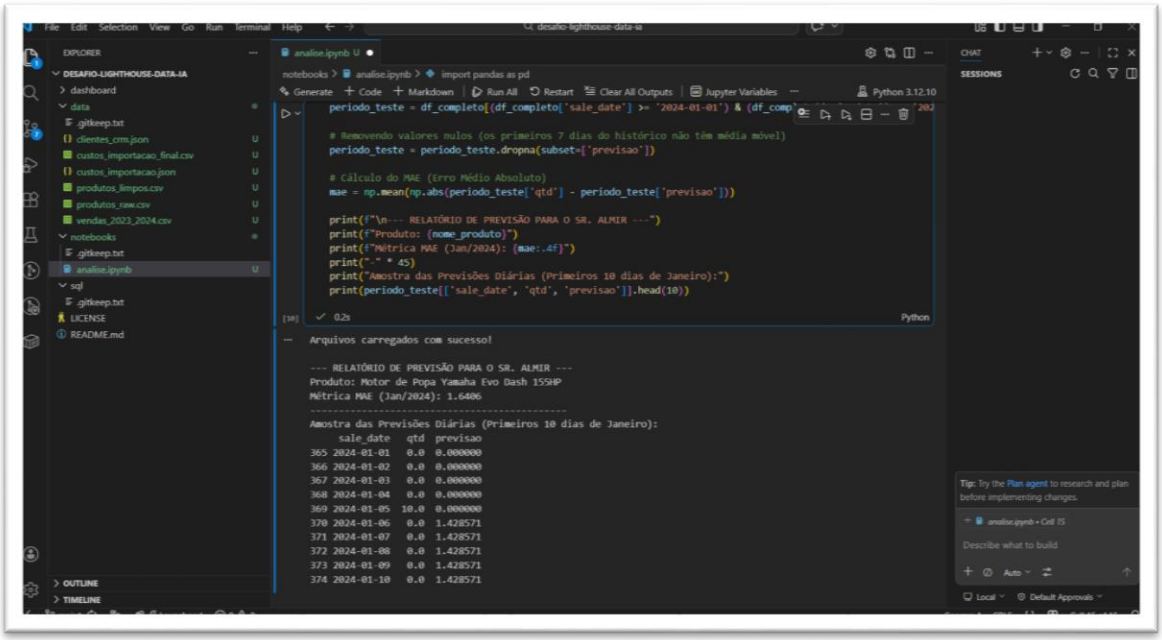

Figura 2: Tabela de previsões diárias demonstrando a métrica de erro e a reatividade do modelo

3.3.Sistema de Recomendação

1. Para a vitrine inteligente, construí uma matriz de interação Usuário x Produto.
2. Similaridade: Utilizei a Correlação de Pearson para medir a afinidade entre os itens.
3. Resultado: O Motor de Popa Volvo Magnum 276HP (ID 1045) apresentou a maior similaridade com o GPS Garmin (0.4312), sendo o item ideal para recomendação.

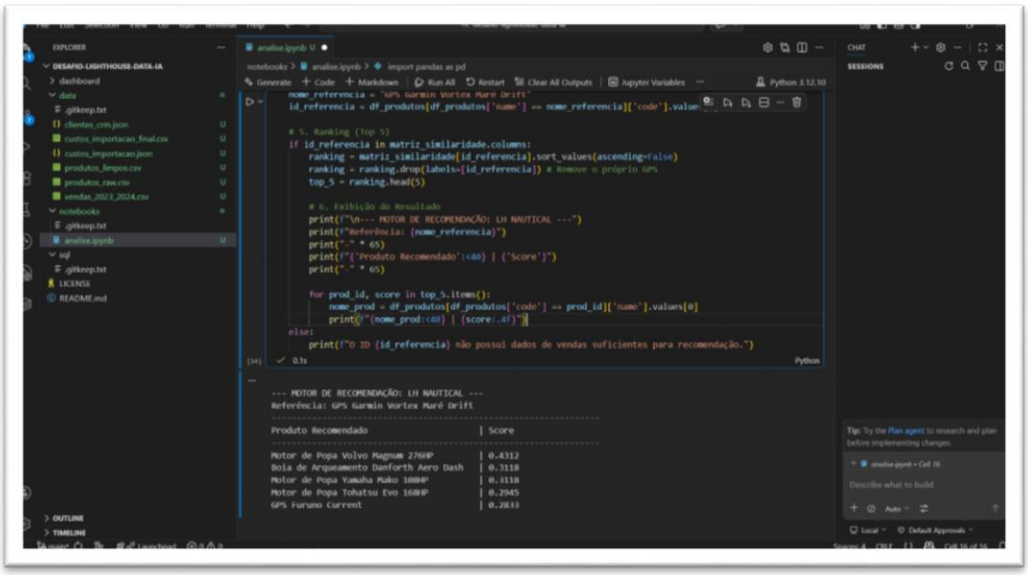

Figura 3 Ranking final de similaridade para estratégias de venda cruzada.

3.4. Análise de Impacto Financeiro no Catálogo

Além da volumetria, realizei uma análise da saúde financeira dos produtos. O gráfico abaixo destaca os itens que geraram o maior prejuízo absoluto no período. Identificar esses "detratores" de margem é fundamental para que a LH Nautical decida entre a renegociação com fornecedores, o ajuste de preços ou a descontinuação de itens que não contribuem para a lucratividade global.

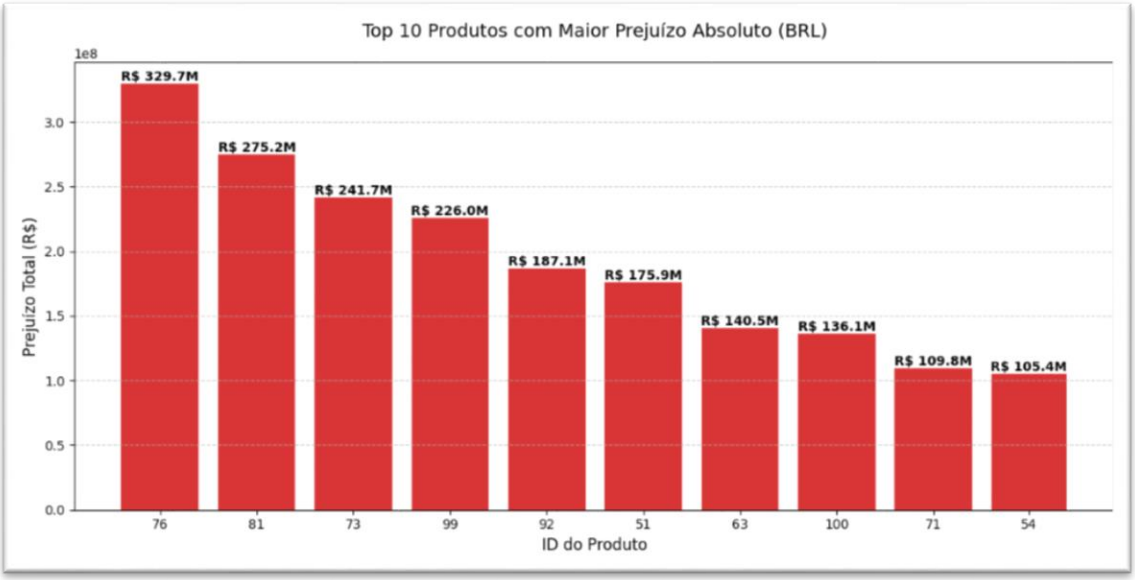

Figura 4: Ranking dos 10 produtos com maior impacto negativo no resultado financeiro absoluto.

4. RELATÓRIO DE INSIGTS E VISÃO DE NEGÓCIO

4.1. Diagnóstico de Estoque: Da Reatividade à Proatividade

A análise do modelo de média móvel evidenciou que a operação atual da LH Nautical ainda possui um caráter predominantemente reativo. O erro de previsão observado no início de janeiro alerta para o risco real de rupturas de estoque caso não haja uma antecipação estratégica aos picos de demanda. Conforme demonstrado visualmente na **Figura 1 (Seção 3.2)**, a incapacidade do modelo *baseline* em reagir prontamente a variações bruscas de vendas reforça a necessidade de evoluirmos para modelos preditivos que incorporem fatores externos. Minha recomendação para a Marina é a transição para uma abordagem que considere a **sazonalidade do setor náutico**, permitindo que o inventário seja preparado com antecedência aos períodos de maior fluxo de buscas e compras.

4.2. Estratégia de Cross-Selling

O motor de recomendação provou que clientes interessados em tecnologia de navegação (GPS) têm alta propensão a adquirir motores de alta performance. Recomendo o agrupamento desses itens em "Combos Premium" no checkout do site para elevar o ticket médio.

4.3. Destaque de Governança de Dados (Data Quality)

Um dos desafios superados foi a padronização das datas. Implementei uma lógica robusta que identifica automaticamente diferentes formatos (BR/ISO), garantindo que a cronologia da análise fosse 100% confiável, eliminando o risco de cálculos errados por falha de leitura.

4.4. Otimização de Processo (Caminhos Relativos)

O projeto foi estruturado utilizando caminhos relativos para os arquivos de dados. Isso significa que qualquer membro da equipe Lighthouse pode rodar o código imediatamente em suas máquinas sem precisar ajustar endereços de pastas, garantindo agilidade e reprodutibilidade.

5. CONCLUSÃO

Este desafio foi uma oportunidade prática de aplicar meus conhecimentos em transição de carreira para a área de dados. Demonstrou a importância de um código limpo, organizado e, acima de tudo, alinhado aos objetivos de negócio.

Como próximos passos de estudo, pretendo explorar modelos de *Machine Learning* mais robustos, como o **Prophet** para séries temporais e técnicas de **Content-Based Filtering** para melhorar a recomendação de novos produtos. Agradeço a oportunidade de participar deste processo seletivo da Lighthouse e coloco-me à disposição para discussões técnicas.